INSTITUTO TECNOLÓGICO DE ZACATEPEC

TECNOLÓGICO NACIONAL DE MÉXICO

MATERIA:

FUNDAMENTOS DE CIENCIA DE DATOS

REPORTE DE PRÁCTICA:

Actividad integradora unidad 2

Inferencia estadística y toma de decisiones en ingenierías

ALUMNOS:

Santiago Ocampo Castro

Moreno Vargas Jesús Alejandro

FECHA: 1 de octubre de 2026

Resumen ejecutivo

Se analizaron tiempos de ejecución de transacciones mixtas mediante un conjunto sintético de 600 observaciones (300 por motor). Tras retirar 18 valores atípicos mediante IQR, quedaron 582 registros. PostgreSQL obtuvo una media de 19.390 ms y MongoDB, 20.590 ms. La prueba t bilateral produjo $t = -2.4435$ y $p = 0.014845$: se rechaza la igualdad de medias con $\alpha = 0.05$. El tamaño del efecto fue pequeño (d de Cohen = −0.203).

1. Planteamiento y metodología

Pregunta de investigación: ¿existe diferencia estadísticamente significativa en el tiempo de ejecución por transacción entre PostgreSQL y MongoDB? Variable cuantitativa: tiempo de ejecución en milisegundos. Variable cualitativa: motor de base de datos. La simulación utilizó distribuciones Gamma desplazadas y una semilla fija. Estos datos no equivalen a mediciones de servidores reales.

Evidencia de generación e inspección del dataset.



0.1 Generación del dataset

Se generan **300 observaciones por motor** (N = 600). Se usan más de las 200 mínimas porque el Bloque 1 elimina valores atípicos y se debe conservar al menos 200 por grupo (N ≥ 400) después de la limpieza.

Parámetros usados:

- PostgreSQL: gamma(forma = 3.0, escala = 4.0) + 8 ms
- MongoDB: gamma(forma = 2.8, escala = 4.5) + 9 ms

```
def generar_dataset(n_por_grupo=300, seed=SEED):
    """Genera tiempos de ejecución por transacción (ms) para ambos motores."""
    rng = np.random.default_rng(seed)
    t_pg = rng.gamma(shape=3.0, scale=4.0, size=n_por_grupo) + 8
    t_mongo = rng.gamma(shape=2.8, scale=4.5, size=n_por_grupo) + 9
    return pd.DataFrame({
        VAR: np.concatenate([t_pg, t_mongo]),
        GRUPO: [G1] * n_por_grupo + [G2] * n_por_grupo,
    })

df_original = generar_dataset()
df_original.to_csv(ARCHIVO_ORIGINAL, index=False)
print(f"Dataset original guardado en {ARCHIVO_ORIGINAL} con {len(df_original)} registros")
```

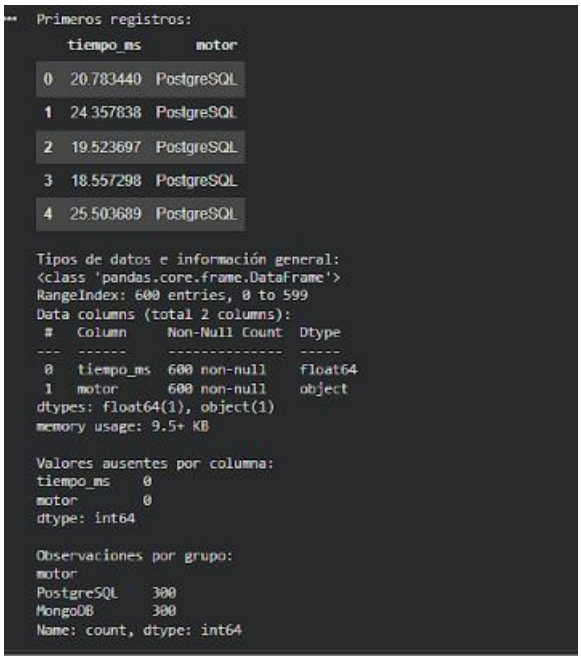
```
Dataset original guardado en data/dataset_caso_b.csv con 600 registros
```

2. Bloque 1 — Estadística descriptiva y limpieza (20 %)

Se verificaron los tipos de datos y la ausencia de valores faltantes. Aplicando el criterio de 1.5 × IQR por grupo se eliminaron 10 registros de PostgreSQL y 8 de MongoDB. La muestra final contiene 290 y 292 transacciones, respectivamente.

Capturas del proceso de depuración y valores atípicos.

Carga y verificación de calidad de datos



```
Primeros registros:
```

	tiempo_ms	motor
0	20.783440	PostgreSQL
1	24.357838	PostgreSQL
2	19.523697	PostgreSQL
3	18.557298	PostgreSQL
4	25.503689	PostgreSQL

```
Tipos de datos e información general:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 600 entries, 0 to 599
Data columns (total 2 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   tiempo_ms  600 non-null    float64
 1   motor      600 non-null    object
dtypes: float64(1), object(1)
memory usage: 9.5+ KB

Valores ausentes por columna:
tiempo_ms    0
motor        0
dtype: int64

Observaciones por grupo:
motor
PostgreSQL    300
MongoDB       300
Name: count, dtype: int64
```

Detección y remoción de valores atípicos (criterio 1.5 × IQR)

```
Registros originales : 600
Atípicos eliminados  : 18
Registros depurados  : 582

Atípicos por grupo:
motor
PostgreSQL    10
MongoDB        8
Name: count, dtype: int64

Observaciones por grupo tras la limpieza:
motor
MongoDB       292
PostgreSQL    290
Name: count, dtype: int64

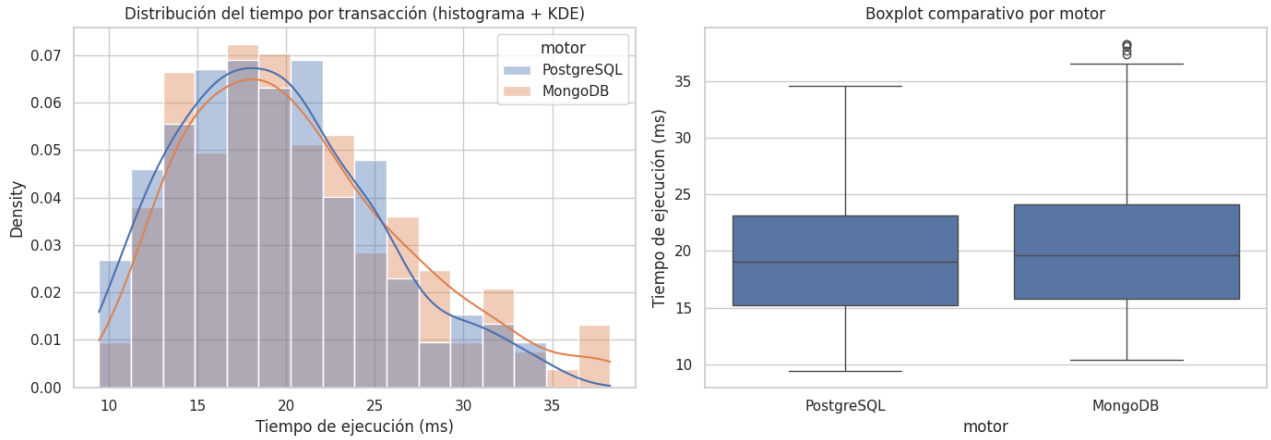
Dataset depurado guardado en data/dataset_caso_b_depurado.csv
```

Estadísticos descriptivos por grupo

motor	n	media	mediana	desv_std	varianza	asimetria	curtosis
MongoDB	292	20.59	19.659	6.233	38.856	0.751	0.130
PostgreSQL	290	19.39	19.065	5.588	31.222	0.528	-0.165

Captura original de métricas descriptivas por motor.

PostgreSQL obtuvo una media de 19.390 ms y MongoDB de 20.590 ms. MongoDB mostró mayor dispersión. La asimetría positiva de ambos grupos indica la presencia de una cola hacia transacciones más lentas.



Histogramas con KDE y diagramas de caja guardados en el notebook.

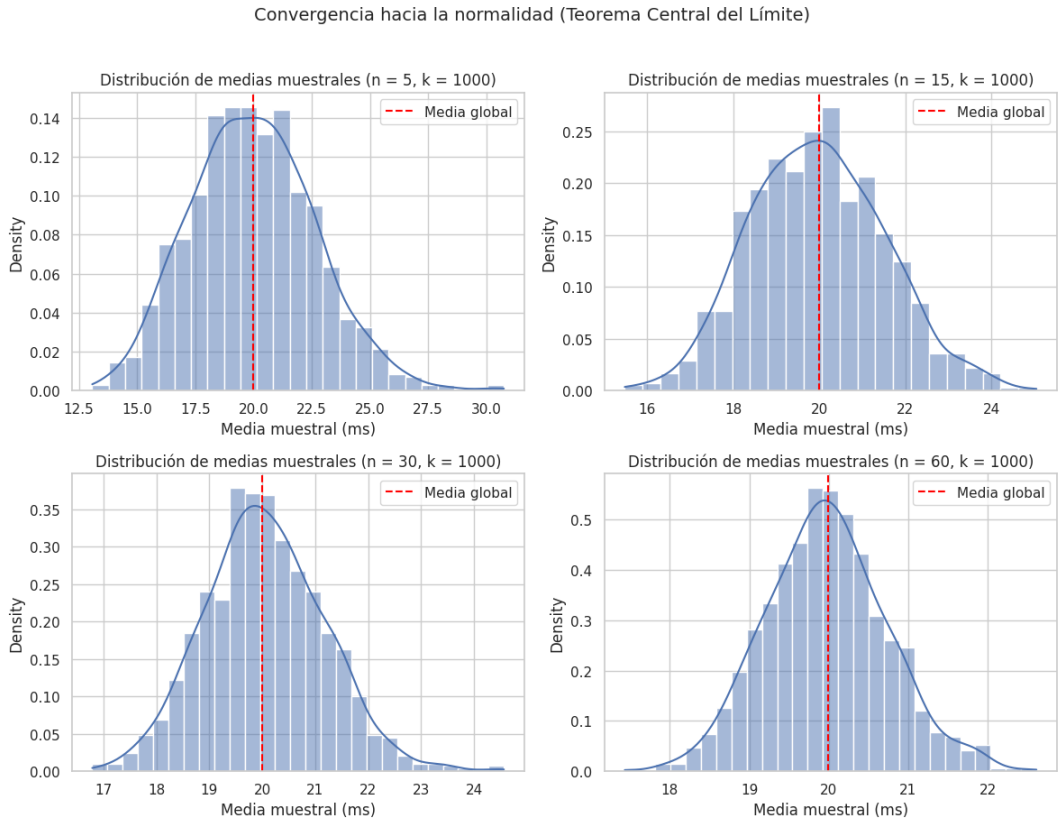
3. Bloque 2 — Teorema Central del Límite (20 %)

Se generaron 1,000 muestras con reemplazo para n = 5, 15, 30 y 60. La media global depurada fue 19.992 ms. Se comparó el error estándar empírico con el teórico (s/√n), comprobando que disminuye conforme aumenta el tamaño muestral.

Muestra global y proceso de remuestreo

```
Tamaño de la muestra global: N = 582
Media global = 19.992 ms | s global = 5.946 ms
Remuestreo completado: {5: 1000, 15: 1000, 30: 1000, 60: 1000} medias por tamaño
```

Parámetros globales utilizados en el remuestreo.



Cuadrícula de cuatro distribuciones de medias muestrales.

	n	media_de_las_medias	SE_empirico	SE_teorico (s/raiz n)	diferencia_%	asimetria_de_medias	curtosis_de_medias
0	5	19.9794	2.6507	2.6590	0.3143	0.2746	0.1171
1	15	19.9678	1.5459	1.5352	0.6954	0.1566	-0.1770
2	30	20.0490	1.1310	1.0855	4.1844	0.2366	0.2721
3	60	19.9697	0.7634	0.7676	0.5410	0.1412	0.1059

Captura del error estándar empírico y teórico.

Los resultados apoyan la convergencia de las medias muestrales hacia una distribución aproximadamente normal y la mejora en su precisión para tamaños de muestra mayores.

4. Bloque 3 — Intervalos de confianza (25 %)

Se utilizó t-Student para estimar la media, puesto que no se conoce la desviación estándar poblacional. Los intervalos de confianza del 90 %, 95 % y 99 % muestran mayor amplitud a medida que crece la confianza.

	nivel	media	t_inferior	t_superior	t_amplitud	z_inferior	z_superior
0	90%	19.992	19.5859	20.3980	0.8121	19.5866	20.3973
1	95%	19.992	19.5079	20.4760	0.9681	19.5089	20.4750
2	99%	19.992	19.3550	20.6289	1.2739	19.3571	20.6268

Captura de intervalos de confianza de la media global.

```
Prueba de Levene: estadístico = 2.0398, p-value = 0.1538
¿Varianzas iguales (p > 0.05)? True  ->  Método: Varianzas combinadas (pooled)

Media PostgreSQL = 19.390 ms | Media MongoDB = 20.590 ms
Diferencia de medias (mu1 - mu2) = -1.199 ms
Error estándar = 0.4908 | gl = 580.00 | t crítico = 1.9641
IC 95% para (mu1 - mu2): (-2.163, -0.235) ms
Verificación con scipy: (-2.163, -0.235) ms
```

Captura de prueba de Levene y comprobación de varianzas.

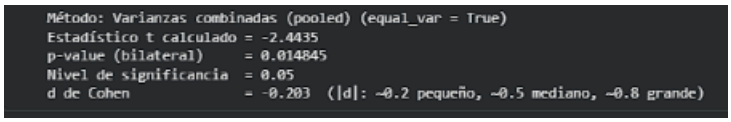


Captura del intervalo de confianza al 95 % para la diferencia de medias.

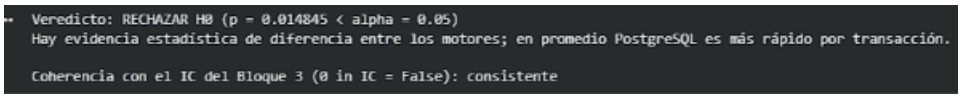
Levene obtuvo p = 0.1538, por lo que no se rechazó la igualdad de varianzas. El intervalo de diferencia PostgreSQL − MongoDB fue de −2.163 a −0.235 ms: no contiene cero y favorece a PostgreSQL en este escenario.

5. Bloque 4 — Prueba de hipótesis y decisión (25 %)

H_0: μPostgreSQL = μMongoDB. H_1: μPostgreSQL ≠ μMongoDB. Con α = 0.05 se aplicó una prueba t bilateral para muestras independientes, usando varianzas combinadas según el resultado de Levene.



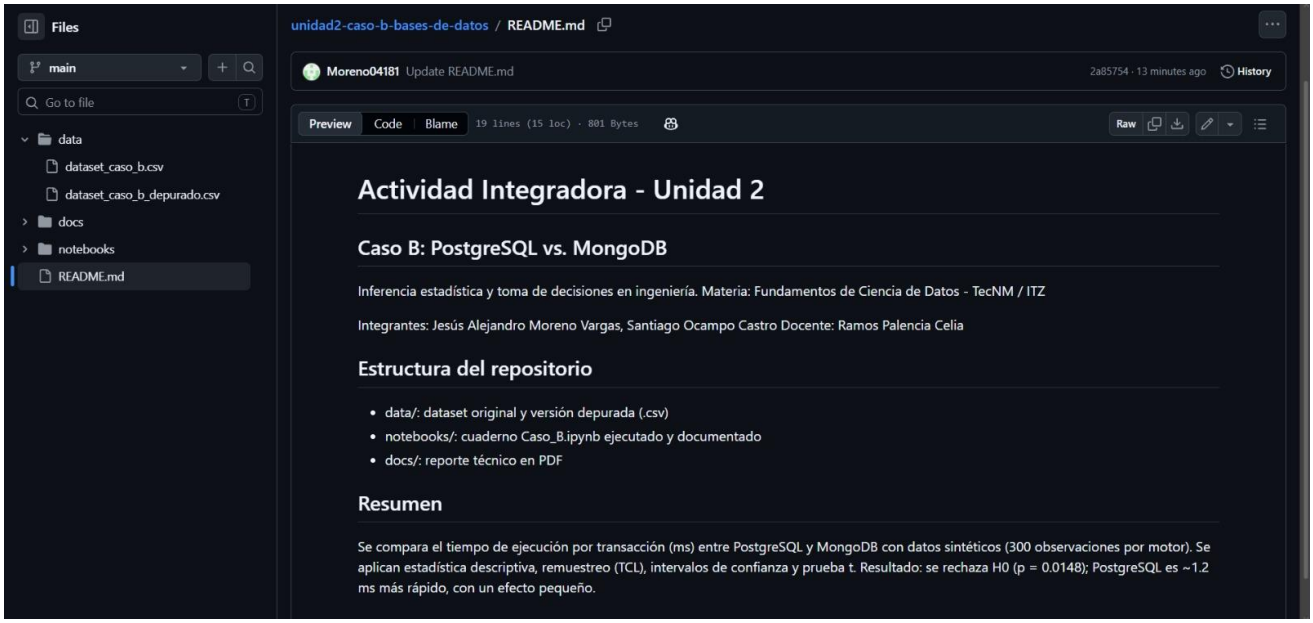
Captura de los indicadores y resultados de la prueba t.



Captura del veredicto estadístico conservado en

Se rechaza H_0 porque p = 0.014845 < 0.05. Un error Tipo I sería recomendar una migración costosa cuando realmente no existe diferencia de medias. Un error Tipo II sería pasar por alto una diferencia existente y mantener una configuración potencialmente menos eficiente. La relevancia práctica es moderada o reducida por el pequeño tamaño del efecto.

Captura de evidencia de Git Hub repositorio



https://github.com/Moreno04181/unidad2-caso-b-bases-de-datos

6. Conclusiones y recomendación técnica

En la simulación, PostgreSQL mostró un menor tiempo de ejecución promedio, con ventaja aproximada de 1.2 ms por transacción. Aunque la diferencia es estadísticamente significativa, no basta para afirmar superioridad en sistemas reales. Se recomienda repetir el experimento en condiciones controladas con cargas representativas y considerar consistencia, escalabilidad, patrón de consultas y costos antes de elegir una base de datos.

7. Referencias

1. National Institute of Standards and Technology. (s. f.). Confidence limits for the mean. NIST/SEMATECH e-Handbook of Statistical Methods. https://www.itl.nist.gov/div898/handbook/eda/section3/eda352.htm

2. SciPy Community. (s. f.). scipy.stats.ttest_ind. SciPy Documentation. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_ind.html

3. SciPy Community. (s. f.). scipy.stats.levene. SciPy Documentation. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.levene.html